Про память

в Python

Обо мне

Юлия Волкова (Iuliia Volkova)



Python Developer в Grid Dynamics



https://medium.com/@xnuinside



xnuinside@gmail.com



https://github.com/xnuinside

На каком уровне говорим



Python Developer level

CPython - Злата Обуховская (Moscow Python)

https://www.youtube.com/watch?v=ISgoYx06L_s&list=PLv_zOGKKxVpi6BSAuySAtX5KyCa50PSCz&index=3

OS

Physical memory level



Дисклеймер

- Говорим про Python 3.7 (преимущественно) и CPython
- В целях соблюдения **NDA** любые намеки на реальный проект удалены, а все совпадения случайны
- Доклад о множестве нюансов, которые прячуться за кажущейся простотой Python, знание подобных нюансов и внимательность позволяет избавить себя от лишней боли и не пропускать на ревью потенциальные источники проблем
- Слайдов много, но я ужимала как могла
- Всё выложу после митапа, все ссылки на код семплы есть в слайдах

Чего в докладе не будет

- 1. Особенностей при работе с mutable типами, где можно получить граблями в лицо на практике, аналогично про lambda, циклы, контексты
- 2. Ошибки при оценки потребления памяти в алгоритмах, количествах комбинаций и т.д.
- 3. Почти не будет про профайлеры, особенности существующих инструментов, тонкости при работе, как использовать на что смотреть
- 4. GC

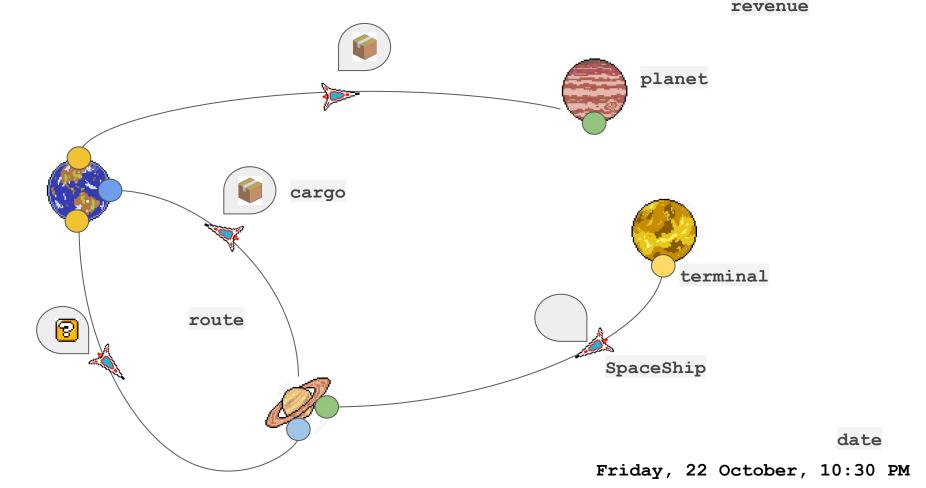
Когда важно думать про память

- Калькуляции вероятностей, комбинаций, анализ событий
- Обработка одновременно большого объема массива, связанных данных
- Любые операции, когда вы вынуждены хранить и "жонглировать" объектами в структурах языка и не можете дергать риалтайм из БД

И тд

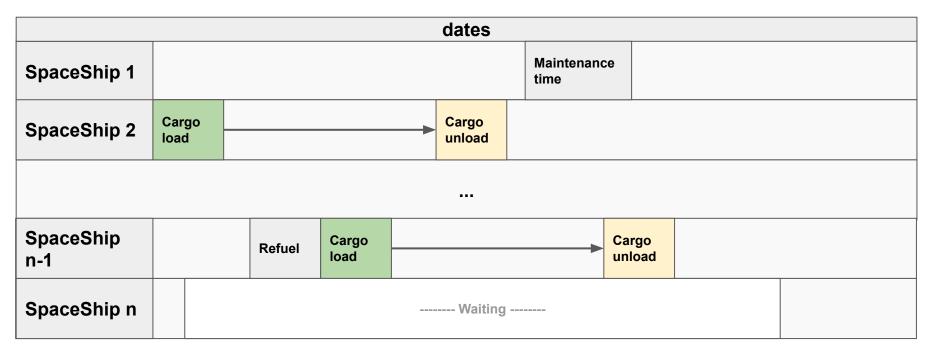
Проект-вдохновение

Total revenue: 5 billions cosmo \$



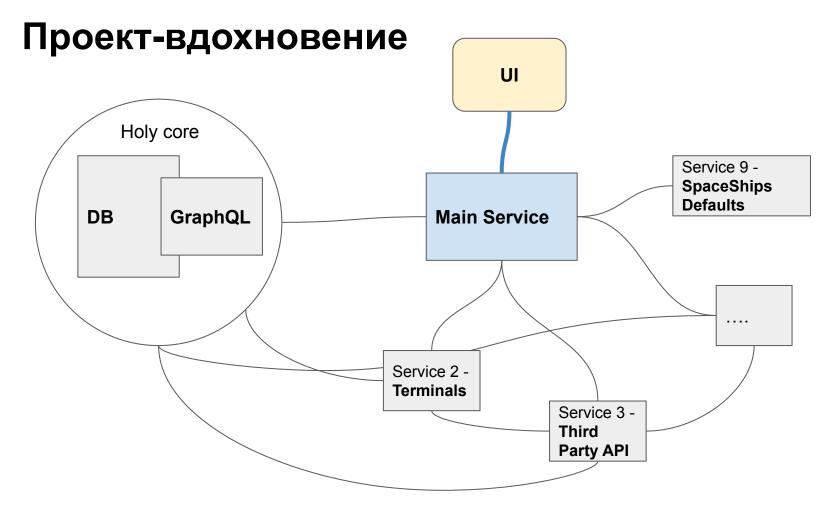
На выходе

Possible risks, cosmo pirates and etc.

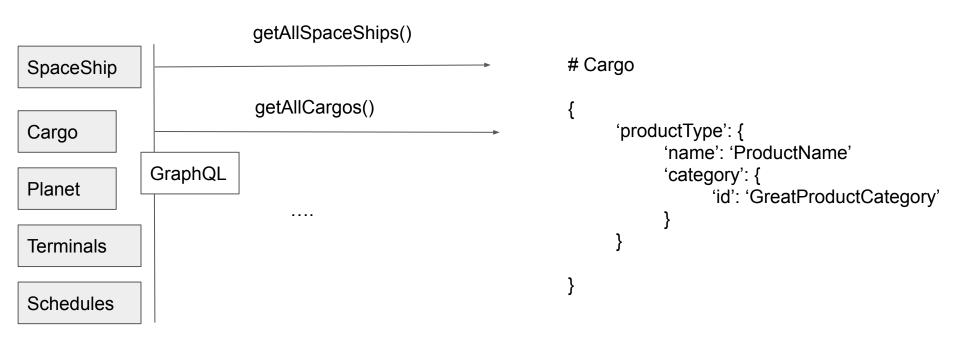


Total revenue:





Проект-вдохновение



For example, SpaceShip: ~ 15 fields, most part of them - nested dicts, lists with dicts and etc.



Начнем с семпла

```
[{"id": 1326380, "product": {"name": "Duper", "uid": "elec109ui"},
 "quantity": {"value": 1165, "id": "mt"}, "dates": {"start":
"2200-10-13T00:00:00",
 "end": "2200-11-13T00:00:00"}},
 {"id": 1710124, "product": {"name": "Elec's0il", "uid": "duper123"},
 "quantity": {"value": 1225, "id": "mt"},
 "dates": {"start": "2200-10-12T00:00:00", "end":
"2200-11-12T00:00:00"}},
{"id": 1013489, "product": {"name": "Elec's0il", "uid": "elec109ui"},
 "quantity": {"value": 1905, "id": "mt"}, "dates": {"start":
"2200-10-13T00:00:00",
 "end": "2200-11-12T00:00:00"}} ...]
```

На что смотреть?

- Процесс создания объектов
- 2. И только потом на размер



1 объект или несколько?

int a = 1;

a = 2;

int b = a;

C









variables

a = 1

a = 2

b = a

Python







names

Сколько объектов?

```
a = 12
b = 12
c = 12

print(id(a))
print(id(b))
print(id(c))
```

```
def function_1_with_low_ints(call_number):
   d = 12
   f = 12
   g = 12
   print(id(a), id(b), id(c))
function 1 with low ints(1)
function_1_with_low_ints(2)
```

1 и тот же объект в функциях и в глобальном скоупе

для int от -5 до 256



А для остальных int?

```
>>> a = 256
>>> b = 256
>>> a is b
True
```

This is not the case if the object referred to is outside the range:

```
>>> a=1234 ; b=1234
>>> a is b
True
>>>
```

Скрин из:

https://medium.com/@tyastropheus/tricky-python-i-memory-management-for-mutable-immutable-objects-21507d1e5b95

(это не единичный пример)

```
>>> a = "python super string"
>>> b = "python super string"
>>> a is b
False
>>> a = "python super string" ; b = "python super string"
>>> a is b
True
```

Так что же с int

```
MacBook-Air:~ xnu$ python3 /Users/xnu/meetup-examples/meetup_examples/realbehavior_example.py
True
True
True
4323700368 4323700368 4323700368 4323700368 4323700368 4323700368
MacBook-Air:~ xnu$ cat /Users/xnu/meetup-examples/meetup_examples/realbehavior_example.py
a = 257
b = 257
c = 257
d = 257
f = 257
a = 257
print(a is a)
print(f is c)
print(b is d)
print(id(a), id(b), id(c), id(d), id(f), id(g))
MacBook-Air:~ xnu$ python2.7 /Users/xnu/meetup-examples/meetup_examples/realbehavior_example.py
True
True
True
(140651125589752, 140651125589752, 140651125589752, 140651125589752, 140651125589752, 14065112558975
MacBook-Air:~ xnu$
```



1 объект в рамках 1 скоупа

```
def function 1 with ints(call number):
  print(f"Function 1 call number {call number}")
   a = 2577
   b = 2577
   print(id(a), id(b), id(c), id(d), id(f), id(g))
function 1 with ints(1)
function 1 with ints(2)
def function 2 with ints(call number):
   print(f"Function 2 call number {call number}")
   . . . .
function 2 with ints(1)
function 2 with ints(2)
```

```
Function 1 call number 1
4564592144 4564592144 ...
Function 1 call number 2
4564592144 4564592144 ...

Function 2 call number 1
4564592336 4564592336 ...
Function 2 call number 2
4564592336 4564592336 ...
```

4564591952 **4564591952**

1 объект для каждой области инициализации



Что со строками?

```
str1 = "name"
str2 = "your"
str3 = "python memory"
str4 = "omg this is amazing python memory"
print(id(str1), id(str2), id(str3), id(str4))
str1 1 = "name"
str2 1 = "your"
str3 1 = "python memory"
str4 1 = "omg this is amazing python memory"
print(id(str1 1), id(str2 1), id(str3 1),
id(str4 1))
```

Тот же id в рамках скоупа, аналогично int

В гитхабе - пример кода с функциями, id будут по 1 штуке для каждого скоупа

4389975216 4391070384 4391070000 4391430064 4389975216 4391070384 4391070000 4391430064



Немного магии

```
c = 500
d = 500
f = 200 + 300

# in 3.6 f will be different from c and d,
in 3.7 - will be the same all 3 ids
print(id(f), id(c), id(d))
```

4554954640 4554954640 4554954640

```
# mathematical operations
a = 200
b = 300
c = 500
d = 500
# pay attention to this line
f = a + b

# in 3.6 and in 3.7!! f will be different
from c and d, interning does not working
print(id(f), id(c), id(d))
```

4554953872 4554954640 4554954640



Конкатенация строк

```
str_name = "name"
str_3 = "3"
str1_3_concat = str_name + str3

str1_3_c_1 = "name" + str(3)

str1_3_c = "name" + "3"
str_c = "name3"

print(id(str1_3_concat), id(str1_3_c_1),
    id(str1_3_c), id(str_c))
```

4447882816 4447682992 4447682736 4447682736

"name3"

80

82 0 LOAD_CONST 2 RETURN_VALUE

0 LOAD CONST

2 RETURN VALUE

1 ('name3')

1 ('name3')



```
1 4504432400 4504432400135673 4507093328 4507093328
```

python **4507705904 4507705904**very long and strange string **4507121184 4507121184**

```
very long and strange string 4507121184 4507121184 very long and strange string inside nested list 4507121184
```

```
python 4507705904 4507705904
135673 4507093328 4507093328
```



Инициализация типов-контейнеров

list

a = [1, 2]b = [1, 2]d = [1, 2]c = [1, 2]print(id(a), id(b), id(d), id(c))

dict

```
a = \{ '1' : 1 \}
b = \{ '1' : 1 \}
d = \{'1': 1\}
c = \{'1': 1\}
print(id(a), id(b),
id(d), id(c))
```

4450065536

4450065696

4450065376

4437969808

```
4331742784
4331742624
```

4331742544

4331047184

tuple

```
a = (1, 2,)
b = (1, 2,)
d = (1, 2,)
c = (1, 2,)
print(id(a), id(b),
id(d), id(c))
```

Python3.6

4346801224 4346801288 4346801352 4346801416

Python3.7

4330278496 4330278496 4330278496 4330278496



Размер: чем будем смотреть?

Pympler - asizeof

Последний релиз - Last released: Apr 5, 2019

Pympler is a development tool to measure, monitor and analyze the memory behavior of **Python objects** in a running Python application.

https://github.com/pympler/pympler

Внутри много разных модулей тирру для онлайн мониторинга и поиска утечек, модули для работы с хипом и т.д.

sys.getsizeof - показывает, только память под сам объект, не учитывает nested объекты



```
28
      int
                 +4 bytes about every 30 powers of 2
      bytes
                 +1 byte per additional byte
37
                 +1-4 per additional character (depending on max width)
49
      str
48/56 (in py37)/ 56(py2.7)
                             tuple +8 per additional item
      list
                 +8 for each additional
64
                 5th increases to 736; 21nd, 2272; 85th, 8416; 341, 32992
224
      set
240
      dict
                 6th increases to 368; 22nd, 1184; 43rd, 2280;
86th, 4704; 171st, 9320
```

Уточню по системе

```
x86_64
```

Darwin Kernel Version 17.7.0: Sun Jun 2 20:31:42 PDT 2019; root:...-4570.71.46~1/RELEASE_X86_64
Darwin-17.7.0-x86 64-i386-64bit

x86 64

Darwin Kernel Version 18.7.0: Thu Jun 20 18:42:21 PDT 2019; root:...-4903.270.47~4/RELEASE_X86_64

Darwin-18.7.0-x86_64-i386-64bit

JSON

File https://github.com/xnuinside/meetup_code_samples/blob/master/meetup_examples/data/cargo.json

File size 1344182 bytes File size 1.28 mbytes читаем в строку

Txt massive 1344232 bytes
Txt massive 1.2819595336914062 mbytes

json.load()

8317088 bytes7.93 mbytes

orjson.loads()

8316688 bytes7.93 mbytes

ujson.load()

11724576 bytes 11.18 mbytes eval(str(json_dict))
python dict by Python

6238824 bytes 5.95 mbytes



Давайте найдем причину

```
"long str1": "python is a very funny language",
                                                        "1345": 1345, "13451": 1345},
global_1 = 1
                                                        {"1": 1, "11": 1, "2": "python", "21": "python",
global 2 = 1
                                                        "long_str": "python is a very funny language",
global_1345_1 = 1345
                                                          "long_str1": "python is a very funny language",
global 1345 \ 2 = 1345
                                                        "1345": 1345, "13451": 1345}]
global str 1 = "python"
global str 2 = "python"
global_long_string_1 = "python is a very funny language"
global long string 2 = "python is a very funny language"
with open("data/small_json.json", 'r') as small_json:
  small json dict = json.load(small json)
  in context int = 1
  in_{context_1345} = 1345
  in context str = "python"
  in context long str = "python is a very funny language"
```

Sample:



[{{"1": 1, "11": 1, "2": "python", "21": "python",

"long str": "python is a very funny language",

Делаем принт

```
print("python", id(global_str_1), id(global_str_2), id(in_context_int)) ...
print('python', id(small_json_dict[0]['2']), id(small_json_dict[0]['21'])) ...
```

global vars and context

```
1 4530581264 4530581264 4530581264
1345 4533240560 4533240560 4533240560
Python 4533542960 4533542960
python is a.. 4533269168 4533269168
```

		<pre>dict1 from json.load()</pre>		<pre>dict2 from json.load()</pre>	
	1	4530581264	4530581264	4530581264	4530581264
	1345	4698025840	4698025840	4698025616	4698025616
F	ython	4698074672	4698074800	4698079280	4698079344
python	is a	4698070272	4698070352	4698070512	4698070592



Вернемся к проекту

```
Мы убедились, что наш дикт не содержит дублирующих int и str, проверили либы
```

Size of dict 1896
Size of dict 'product' 488
Size of dict 'quantity' 448
Size of dict 'dates' 504

```
# product
{"name": "Elec'sOil", "uid": "elec109ui"}
```

Size of dict 'product' 488

Начнем с оптимизации этого куска



Попробуем другие контейнеры

	Размер bytes	Доступ через ['key']
dict	488	да	<pre>{"name": "Elec'sOil", "uid": "elec109ui"}</pre>
frozendict	800	да	<pre>frozendict({"name": "Elec'sOil", "uid": "elec109ui"})</pre>
namedtuple	200	нет	<pre>product = namedtuple("ProductNamedTuple", ['name', 'uid'] pr_named_tuple = product("Elec'sOil", "elec109ui")</pre>
tuple	200	нет	("Elec'sOil", "elec109ui")
object	424	да	class Product>



```
328
```

```
424
class Base:
  def setitem (self, key, value):
      self. dict [key] = value
  def getitem (self, key):
      return self. dict [key]
class Product(Base):
  def init (self, name, uid):
      self.name = name
      self.uid = uid
```

```
class Base:
  def setitem (self, key, value):
      self. dict [key] = value
  def getitem (self, key):
      return self. dict [key]
class ProductSlots(Base):
  slots = ['name', 'uid']
  def init (self, name, uid):
      self.name = name
      self.uid = uid
```

```
print("Size of one Product __dict__",
asizeof(one_product.__dict__)) -> Size of one Product __dict__ 360
```



Можем лучше

```
328
class Base:
  def setitem (self, key, value):
      self. dict [key] = value
  def getitem (self, key):
      return self. dict [key]
class ProductSlots(Base):
  slots = ['name', 'uid']
  def __init__(self, name, uid):
      self.name = name
      self.uid = uid
```

```
class BaseSlots:
  slots = []
  def setitem (self, key, value):
      self. setattr (key, value)
  def getitem (self, key):
      return self. getattribute (key)
class ProductSlotsWithBaseSlots(BaseSlots):
  slots = ['name', 'uid']
  def init (self, name, uid):
      self.name = name
```

self.uid = uid

dict 488 → **object 192**

Sample:



192

Переведем всё в объекты

 $1896 \to 688$



Посмотрим на листе с 5 строками

 $6928 \rightarrow 2840$





Добавим init только одного инстанса

1 объект на 1 сет аргументов

 $2840 \rightarrow 2648$

Пока не понятно..

```
class OptimisedBaseUniq:
  slots = []
  instances = {}
   def new (cls, *args, **kwargs):
      # you can make it better!
      instance args = str(list(args) + list(kwargs.values()))
      if instance args in cls. instances:
          return cls. instances[instance args]
      else:
          obj = super(OptimisedBaseUniq, cls). new (cls)
          cls. instances[instance args] = obj
          return obi
   def getitem (self, key):
      return self. getattribute (key)
```



Загрузим файл побольше

```
File size: 1344182 bytes (1.2819 mbytes) cargo.json
```

```
Dicts size: 6238824 bytes 5.9498 mbytes
```

Non-unique: Size with optimized objects 1918712 bytes 1.8298 mbytes

Unique objects: Size with optimized unique product objects 1535736 bytes

1.4646 mbytes

Но надо очень аккуратно с _instances



Так, стоп, а что с perfomance 10000 runs

```
def find all dates in multi cargo example():
   dates = [event['dates'] for event in multi cargo example]
   return dates
def find product with name dict():
   for i in multi cargo example:
       if i['product']['name'] == "Elec'sOil":
           return i
def while products all dates in multi cargo example():
   while cargo copy dict:
       i = cargo copy dict.pop()
       if i['product']['name'] == "Elec'sOil":
           return i
def get id in multi cargo example():
   for i in multi cargo example:
       return i['id']
```

Find all dates and return list Dict 0.3583587479999999 Object 1.4361160179999999

Find first product with name with for Dict 0.002828282999999315 Objects by keys **0.011392252999999908**

Search first elem with product name == Elec'sOil with while and pop Dict 0.0033425770000001798 Objects by keys **0.004955137000000054**

Return id of first element Dict 0.001728861000000137 Objects by keys **0.004175465999999961**



А если атрибуты

```
def find all dates in optimized access by arg():
  dates = [event.dates for event in
optimized multi cargo unique product]
  return dates
def find first product byid in optimized():
  for i in optimized multi cargo unique product:
       if i.product.name == "Elec'sOil":
           return i
def while all dates in optimized with arg():
  while cargo copy optimized:
       i = cargo copy optimized.pop()
       if i.product.name == "Elec'sOil":
           return i
def get id by arg optimized():
  for i in optimized multi cargo unique product:
       return i.id
```

10000 runs

Find all dates and return list
Dict 0.358358747999999
Objects by id 0.251415976000001

Find first product with name with **for**Dict **0.002828282999999315**Objects by id **0.0030798729999998997**

Search first elem with product name ==
Elec'sOil with while and pop
Dict 0.0033425770000001798
Objects by id 0.0011348099999999306

Return id of first element
Dict 0.001728861000000137
Objects by id 0.0015311040000001164



А давайте последний тест

```
def find_product_with_name_dict_list():
    return [i for i in
    optimized_multi_cargo_unique_product if
    i['product']['name'] == "Elec'sOil"]

def find_first_product_byid_in_optimized_list():
    return [i for i in
    optimized_multi_cargo_unique_product
        if i.product.name == "Elec'sOil"]
```

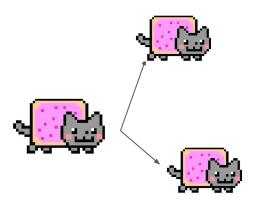
10000 runs

```
Find all elems with product == name
with for and return list
```

```
Dict 6.373839168999999
Objects by dict keys 4.485599703
```



Дерево родни для кисы



```
create\_tree \quad \to \quad cat\_relative\_ids
```

```
def cat_relative_ids(cat_id, cat_family=[]):
    [cat_family.append(x) for x in range(10)]
    return cat_family

cat_relative_ids(1)
ids = cat_relative_ids(2)
print(len(ids))
```

defaults

```
def cat_relative_ids(cat_id, cat_family=[]):
    cat_family_from_db = db.query(
        Cat, Cat.relations, cat_id)
    return cat_family
```

Чаще это '{}' в defaults

```
27
        0 LOAD CLOSURE
                                0 (cat family)
       2 BUILD TUPLE
       4 LOAD CONST
                              1 (<code object
listcomp> at 0x10402c780, file
".../meetup examples/realbehavior example.py", line 27>)
       6 LOAD CONST
('cat_relative_ids.<locals>.<listcomp>')
       8 MAKE FUNCTION
       10 LOAD GLOBAL
                              0 (range)
       12 LOAD CONST
                              3 (10)
       14 CALL FUNCTION
       16 GET ITER
       18 CALL FUNCTION
      20 POP TOP
28
                               0 (cat family)
       22 LOAD DEREF
      24 RETURN VALUE
```

Что мы использовали

- 1. Pympler asizeof
- 2. id()
- dis.dis()

Что есть ещё

- 1. Зоопарк модулей Pympler-a (included Muppy, SummaryTracker, ClassTracker, Heap и тд) https://github.com/pympler/pympler
- 2. Heapy из Guppy3 https://github.com/zhuyifei1999/guppy3/ (сейчас посмотрим один из отчетов, что он дает)
- 3. memory_profiler (очень много HO) https://github.com/pympler/pympler
- 4. Objgraph (Python Object Graphs https://mg.pov.lt/objgraph/)
- 5. Tracemalloc (Standard Library)
- Pysizer (мёртв?) Python 2.5?
- 7. Если что забыла докиньте в канал



memory_profiler magic

```
def funct_to_profile():
    a = lambda: 10
    b = lambda: 10
    print(h.heap())
    a()
    b()
    big_list_check = [{'1': 1} for _
in range(100000)]
    print("asizeof ",
asizeof(big_list_check))
    print(h.heap())
    c = big_list_check
```

```
from guppy import hpy
h = hpy()
print(h.heap())

Давайте, просто на всяяяяякий случай возьмем другой профайлер
```

```
Line #
          Mem usage
                       Increment
                                   Line Contents
           31.4 MiB
                        31.4 MiB
                                   def funct_to_profile():
    10
                        0.0 MiB
                                       a = lambda: 10
    11
           33.2 MiB
                        0.0 MiB
                                       b = lambda: 10
    12
          33.2 MiB
                                       print(h.heap())
    13
          33.2 MiB
                        1.8 MiB
    14
          33.2 MiB
                         0.0 MiB
                                       a()
                                       b()
    15
          33.2 MiB
                         0.0 MiB
                         0.7 MiB
                                       big_list_check = [{'1': 1} for _ in range(100000)]
    16
          60.0 MiB
                                       print("asizeof ", asizeof(big_list_check))
    17
          67.6 MiB
                        7.5 MiB
                        2.6 MiB
                                       print(h.heap())
    18
          70.2 MiB
    19
          70.2 MiB
                         0.0 MiB
                                       c = big_list_check
```

Неару в тот же момент, в том же вызове

```
До создания листа big_list_check = [{'1': 1} for _ in range(100000)]
```

```
Partition of a set of 111079 objects. Total size = 15374593 bytes.
                    Size % Cumulative % Kind (class / dict of class)
       30718 28 4556540 30
                             4556540 30 str
       29611 27 2483568 16
                             7040108 46 tuple
                         7 8174972 53 bytes
             14 1134864
                              9269388 60 types.CodeType
                 1094416
                          7 10299276 67 function
              6 1029888
                  913208
                          6 11212484 73 type
        1050
        1722 2
                  736400
                          5 11948884 78 dict (no owner)
                  601224
                         4 12550108 82 dict of module
                  482824
                         3 13032932 85 dict of type
                  262512
                         2 13295444 86 _io.BufferedWriter
```

После (обратите внимание также на asizeof)

```
asizeof 25624560
Partition of a set of 211093 objects. Total size = 40999745 bytes.
                           % Cumulative % Kind (class / dict of class)
 Index Count
              48 25536528
                          62 25536528 62 dict (no owner)
                  4556540
                          11 30093068
                                        73 str
                  2483928
                           6 32576996 79 tuple
       15103
               7 1134864
                           3 33711860 82 bytes
               4 1094416
                           3 34806276 85 types.CodeType
                                       87 function
               3 1029888
                           3 35836164
        1050
                   913208
                           2 36749372
                                        90 type
         433
                   913096
                           2 37662468 92 list
                   601224
                           1 38263692 93 dict of module
                   482824
                          1 38746516 95 dict of type
```

A вот хип до from pympler.asizeof import asizeof

```
Partition of a set of 36070 objects. Total size = 4587406 bytes.

Index Count % Size % Cumulative % Kind (class / dict of class)

0 10299 29 911404 20 911404 20 str

1 8834 24 717136 16 1628540 36 tuple

2 2331 6 337000 7 1965540 43 types.CodeType
```

Sampler:

https://github.com/xnuinside/meetup_code_s amples/blob/master/meetup_examples/profile rs_memory_fun.py



Заключение

- 1. Проверяйте профайлеры профайлерами. У нас тут Python.
- 2. Не забывайте про то, что ваши переменные это ссылки, а объекты порой могут жить своей жизнью. Убивайте за mutable в дефолтных значениях функций.
- 3. Пользуйтесь id(), dis.dis() и pymler. Все свои предположения проверяйте, потому что вполне возможно всё совсем не так
- 4. Не верьте либам, которыми пользуетесь, скорее всего до вас вообще никто не думал про память
- 5. Вода мокрая, огонь горячий и т.д.

Вопросы?